So - AI 搜索与知识整理智能助手软件[简称：So]V5.3.0

产品说明书

软件介绍

软件名称：So，AI 搜索与知识整理智能助手软件

简称：So

版本号：V5.3.0

软件类别：人工智能软件

软件特色

一个可在 macOS 上执行信息挖掘的 AI 智能助手。它可以自由搜索 Google、X、Reddit、Baidu、小红书、微信公众号等平台，使用 AI 回答，并对 AI 回答进行事实核查。

系统需求

本软件适用系统：Mac OS 26.0 及以上操作系统

安装和运行方法

安装方法：在“https://github.com/yyaadet/So”下载本软件安装包，根据提示进行软件安装。

运行方法：

- 本地安装有 Ollama 或是从外部 MASS 平台购买了大模型 API
- 安装完成之后，点击软件“图标图样”，即可开启本软件。

目录

1 软件功能 2

1.1 主页面 2

1.2 设置界面 3

1.2.1 常用设置 3

1.3 大模型设置 3

1.3.1 订阅设置 6

1.3.2 邮件发送服务器设置 7

1.3.3 搜索设置 8

1.4 对话界面 9

1.5 知识库管理界面 15

1.6 浏览器界面 18

1 软件功能

1.1主页面

进入主页面，用户能看到三部分内容。左边是对话主界面。中间是知识库管理主界面。右边是浏览器界面。

如下图所示：

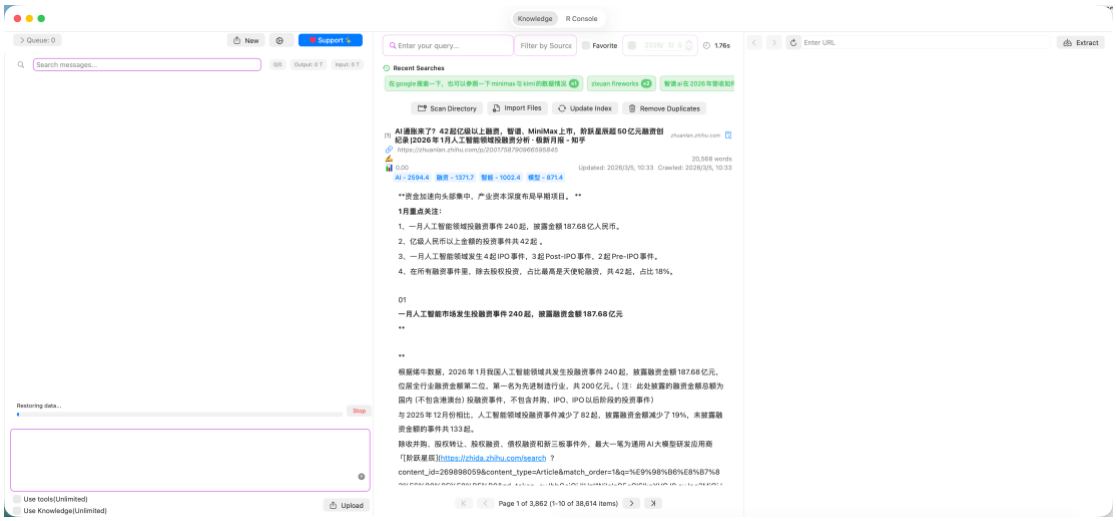

1.2设置界面

1.2.1常用设置

- ✓ 可以设置字体大小。会影响对话、知识库的显示字体大小。
- ✓ 是否使用本地的 Embedding 向量。如果不使用本地 Embedding，默认使用 ollama 配置的 qwen-embdding 模型（需要用户配置）。
- ✓ 推理深度。支持低、中、高三档。

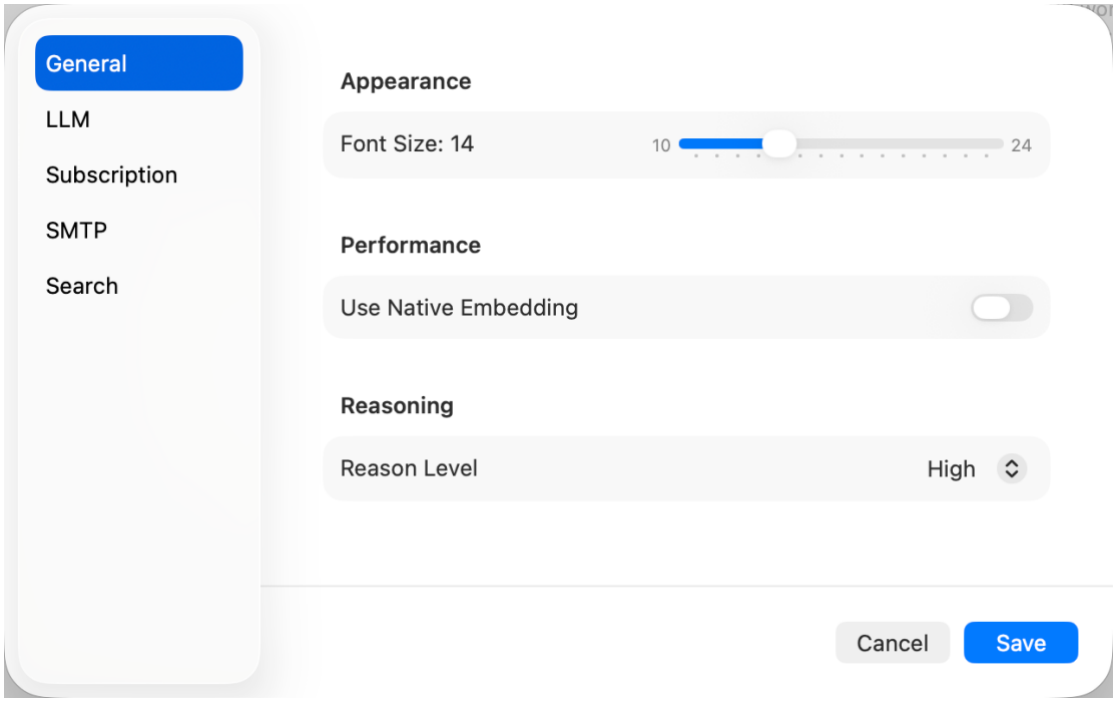

1.2.2大模型设置

- ➢ 温度设置。用以控制大模型输出的新奇度。
- ➢ Top P 设置。用以控制大模型输出的唯一性。
- ➢ 最大聊天历史。用以控制在对话时，有多少历史对话会发达到 LLM 上下文。
- ➢ 超时时间。等待大模型反应的最大时间。
- ➢ 上下文长度。控制可以发达到大模型的上下文长度，超过部分会被截断。

- 最大分块大小。当文档过长时候，会以分块大小进行分块，有助于回答用户问题的块会被发送到大模型。
- 最大引用文档数量。当开启了使用本地知识库或工具时候，控制可以发达到大模型的最大文档数量。
- 最小重排得分。只有文档重排后，得分高于这个值，才会被送到大模型。
- 最小 BM25 得分。第一轮粗筛时候，只有 BM25 得分高于这个分数，才能进入重排流程。
- 语言。选择大模型对话使用的语言，支持中文与英文、自动模式。
- 供应方。用户可以动态增加、删除、编辑 Ollama 与 OpenAI 接口形式的 API。

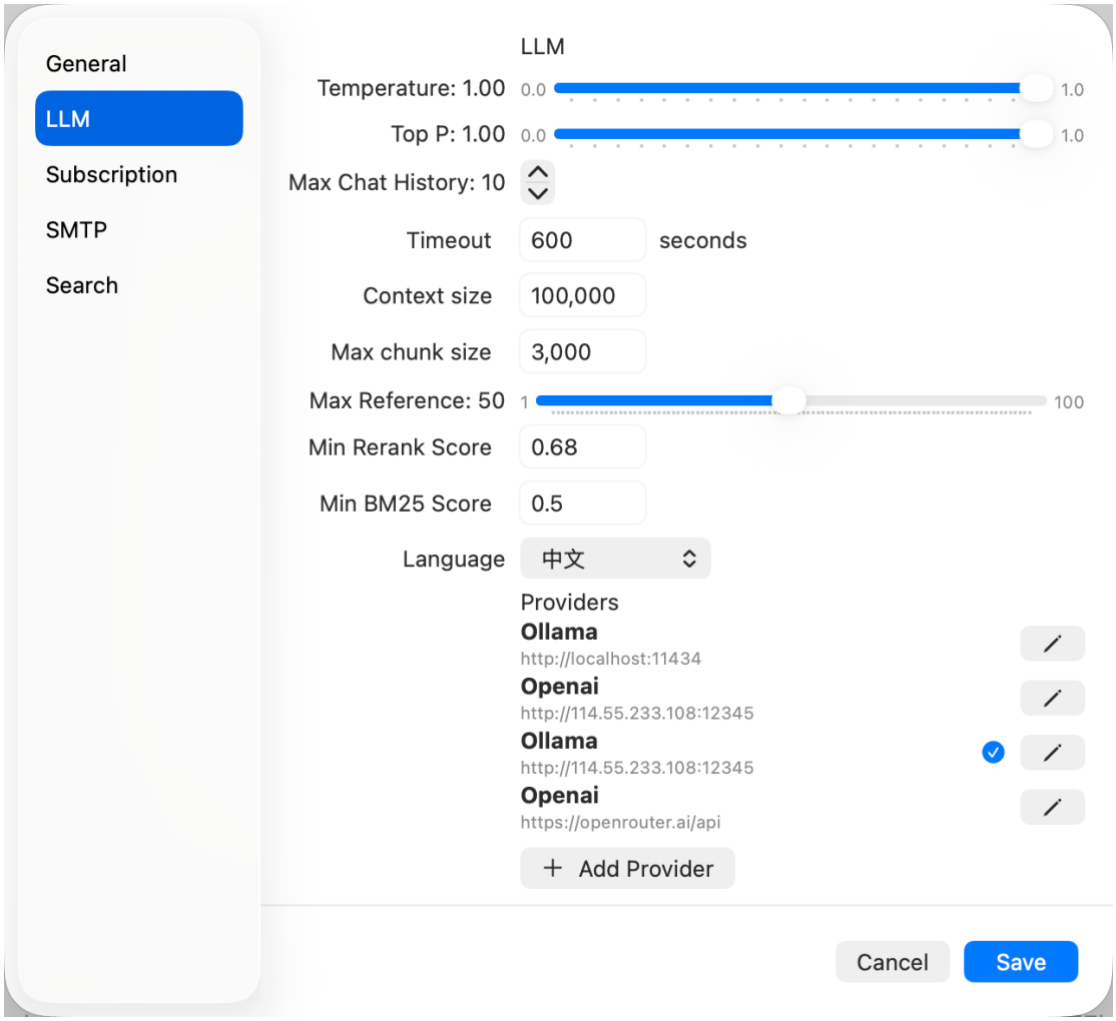

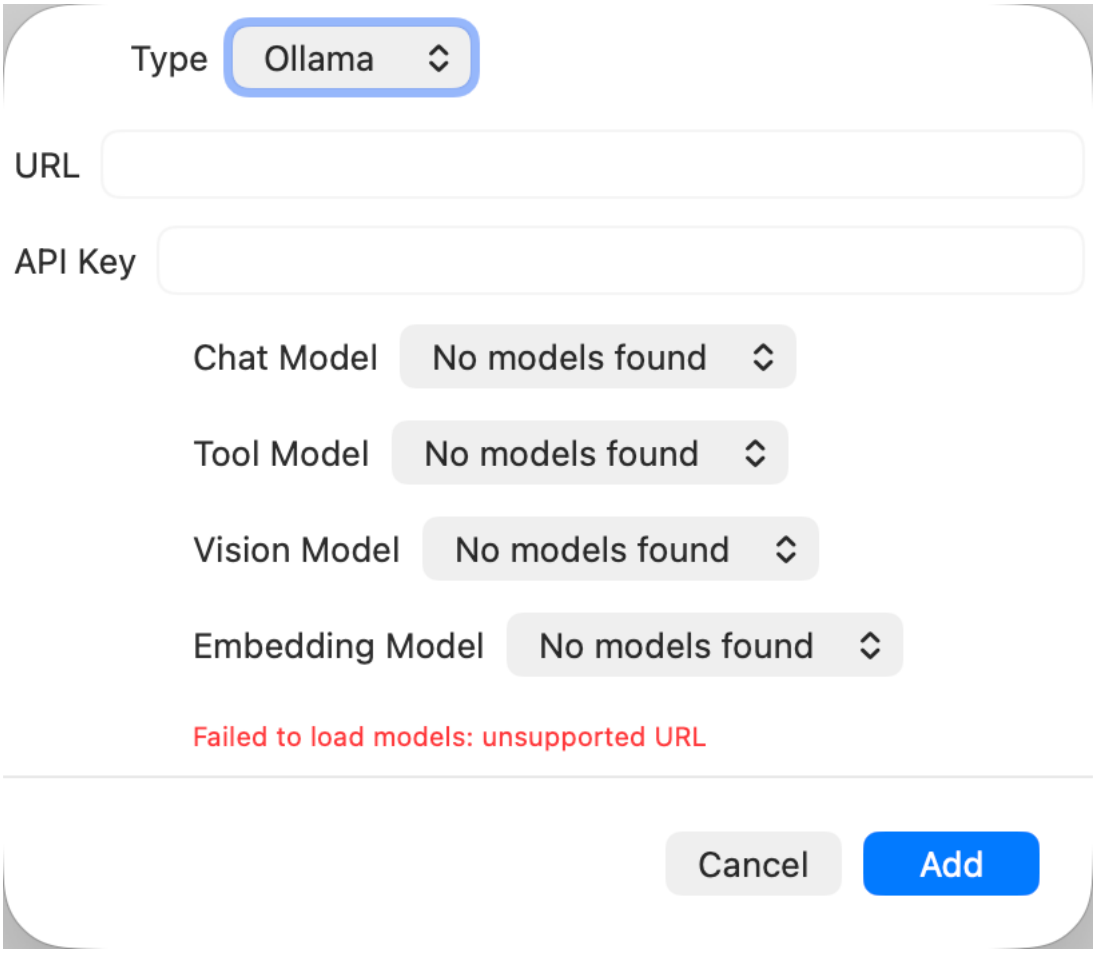
Type
Ollama
URL
API Key
Chat Model
No models found
Tool Model
No models found
Vision Model
No models found
Embedding Model
No models found
Failed to load models: unsupported URL
Cancel
Add

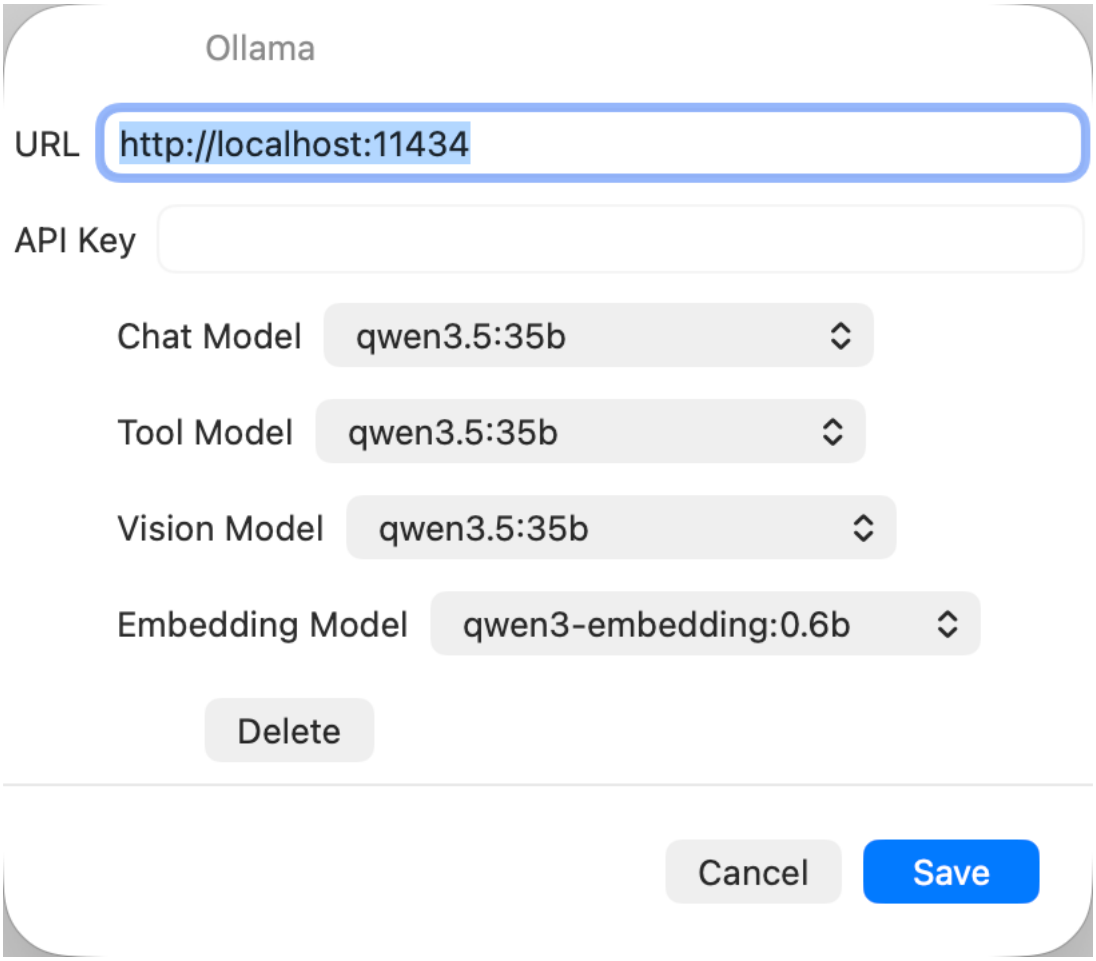

1.2.3 订阅设置

需要用户添加自己的 API key 与 secret 才能开启使用工具与本地知识库搜索功能。

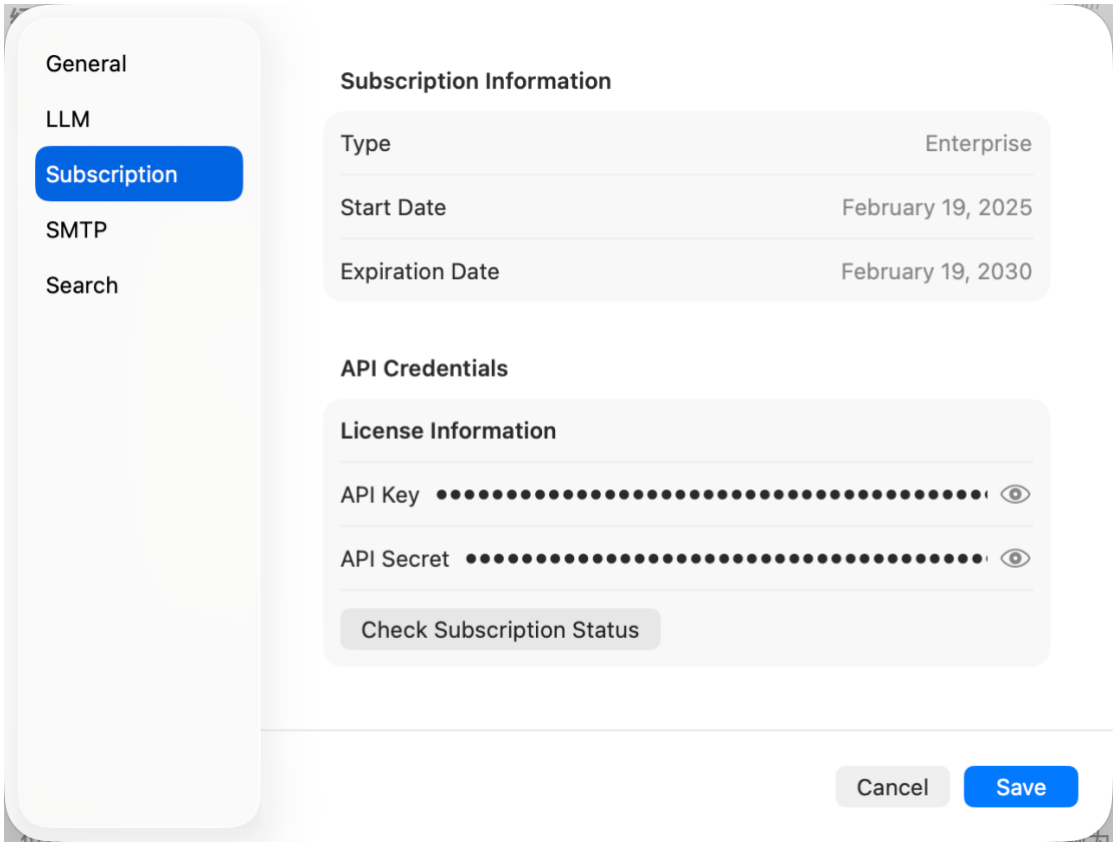

1.2.4 邮件发送服务器设置

设置好邮件发送服务后，当定时任务完成时，会给邮箱发送邮件。

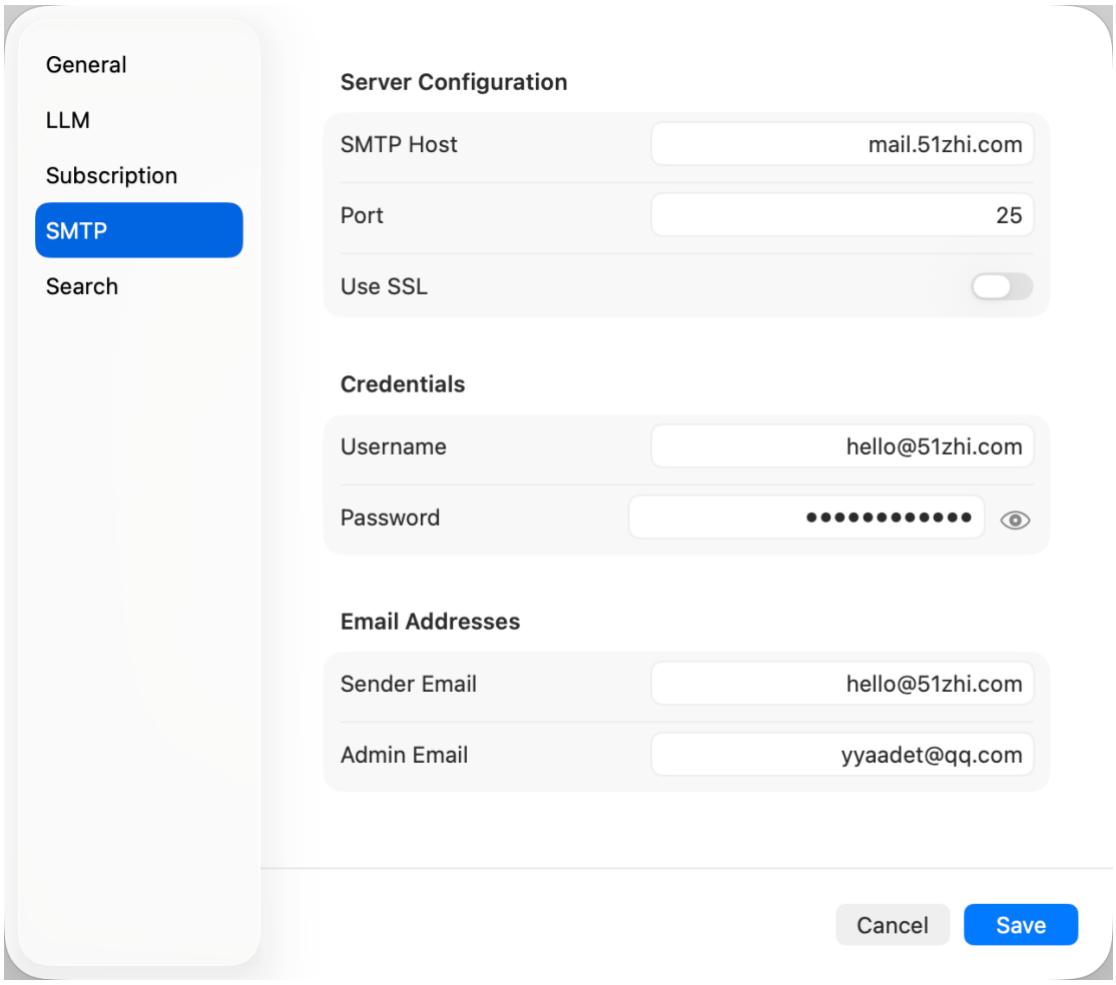

1.2.5搜索设置

用以控制搜索行为的，由于使用的是 BM25 搜索算法，K1、B、Delta 这三个参数都可以修改，会直接影响知识库搜索时候的返回结果。

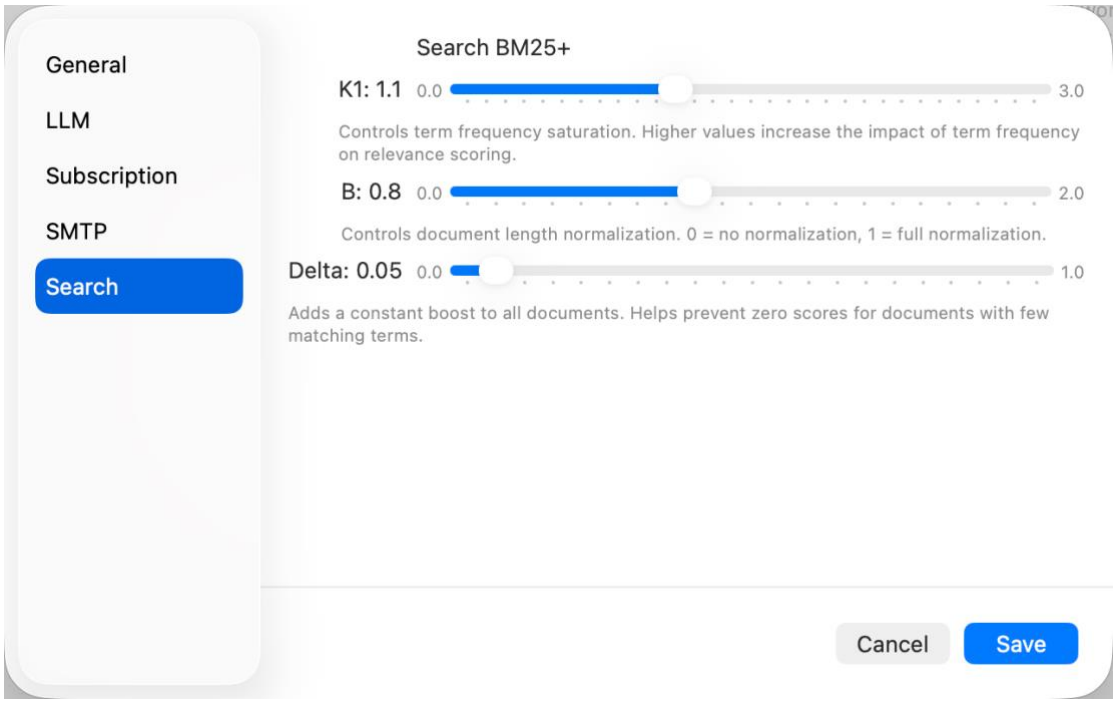

1.3对话界面

用户通过对话的方式，可以让大模型基于本地的知识库或是互联网内容。用户如果勾选上“User tools”框，就会与设置好的大模型进行交互，选择最合适的工具来完成用户的问题或需求。如果勾选上了“Use knowledge”，会根据用户的输入搜索本地知识库，然后进行回答。如果两者都没有勾选，将不进行任何搜索，直接与大模型进行对话。

用户点击按钮“New”，当前的对话将以任务的形式保存下来，在左侧隐藏的树形任务里面可以搜索到，同时当前的对话将清空，准备新的对话。

用户也可以从当前对话删除消息、拷贝消息到剪切板、保存消息到本地文件。

主对话窗口	**左侧隐藏了过去所有对话历史**

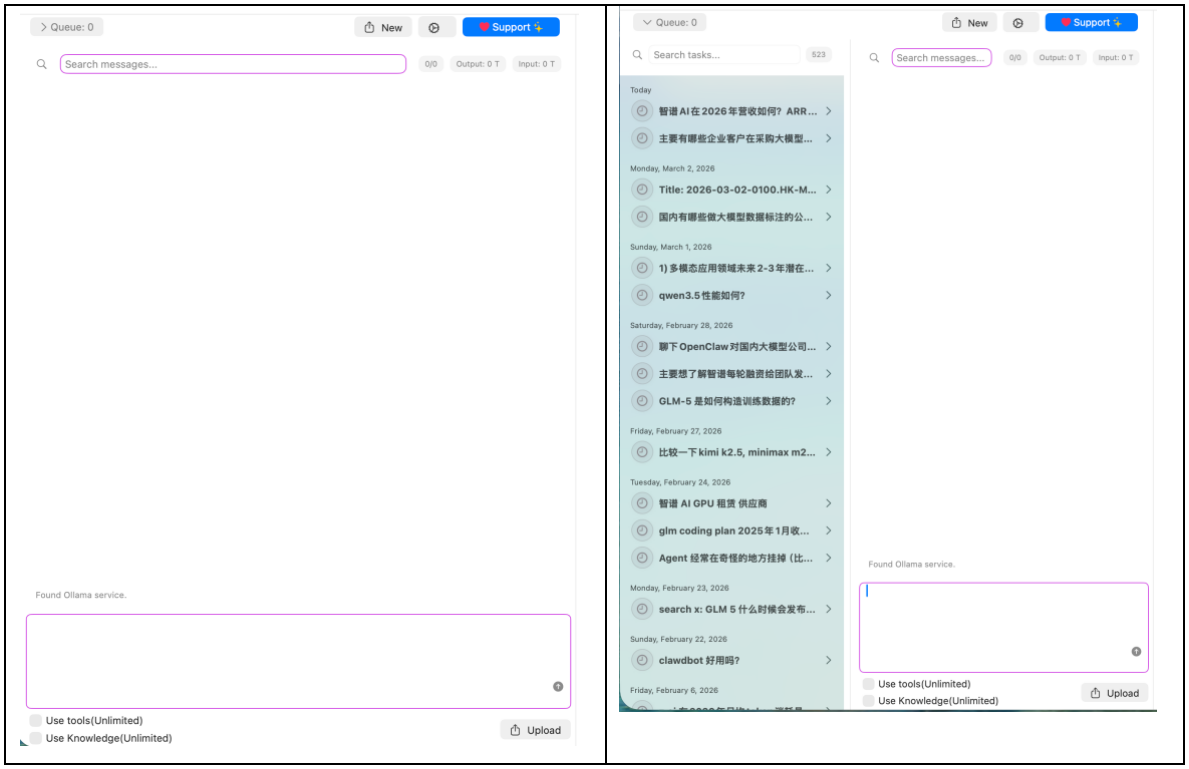

用户可以按关键词搜索当前对话的所有消息，并且右侧会展示消息条数、输出 Token 总数、输入 Token 总数，输入输出是根据大模型返加的指标统计得到。

比如我们可以搜索：“minimax”。下图是搜索后的结果展示。

当开启了“Use tools”或是“use knowledge”时，大模型的回答里面可能会包含引用的文档。可以点击“view all references”按钮来打开，查看引用文档。在引用文档里面，会列出大模型的回答引用了实际的哪些文档内容文字。绿色代表大模型的回答，紫色代表的是文档的中引用文字。如下图：

如果大模型的回答里面出现 R 代码，也可以在本地直接运行，前提是本地已经安装了 R 的运行环境。如下图：

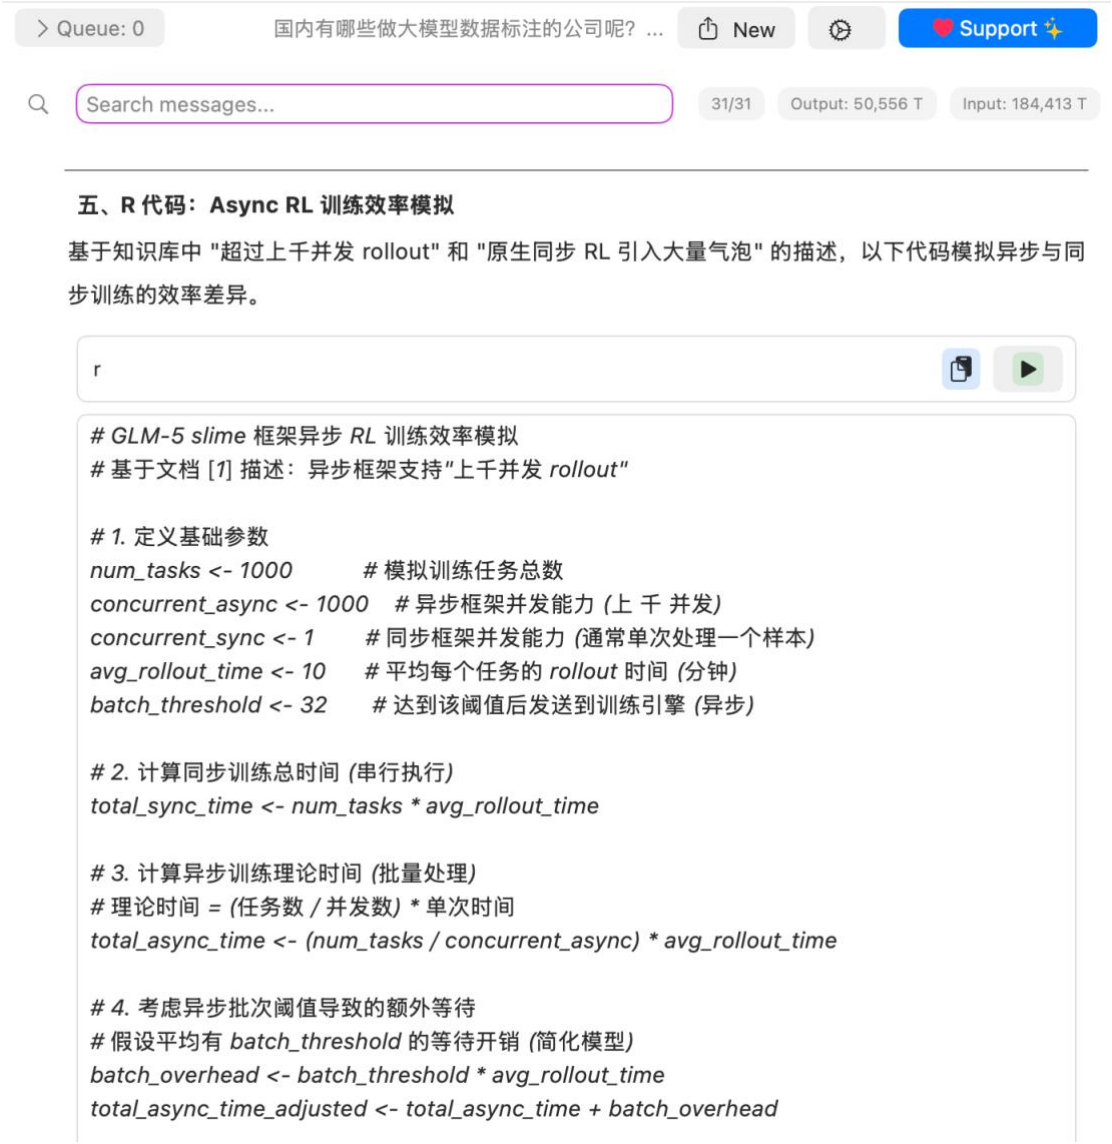

在树形任务栏里面，可以删除、运行、查看任务，还可以为任务设置定时周期。定时周期，可以设置分、时、日、月、周几，这样任务就会反复执行。

在对话框里面打字的同时，后台也在检索过去最相似的消息，可以提高用户输入的效率。比如我打字输入：“minima”，就会给出可能的建议。

1.4知识库管理界面

知识库，都保存在本地。可以通过扫描本地目录、导入文件的方式，来导入本地内容到知识库里面。也可以通过“Update Index”来更新知识库索引，提升准确率与性能。点击按钮“Remove Duplicates”，会删除掉相同的知识库内容。

在搜索框里面，输入想要查询的内容，软件会根据关键词进行搜索。用户也可以增加源、是否收藏、最后创建时间来筛选知识库。

用户可以查看每条知识的详细内容，如果知识来自小红书、X，可以查看到对应的评论数据。评论数据，也支持搜索。

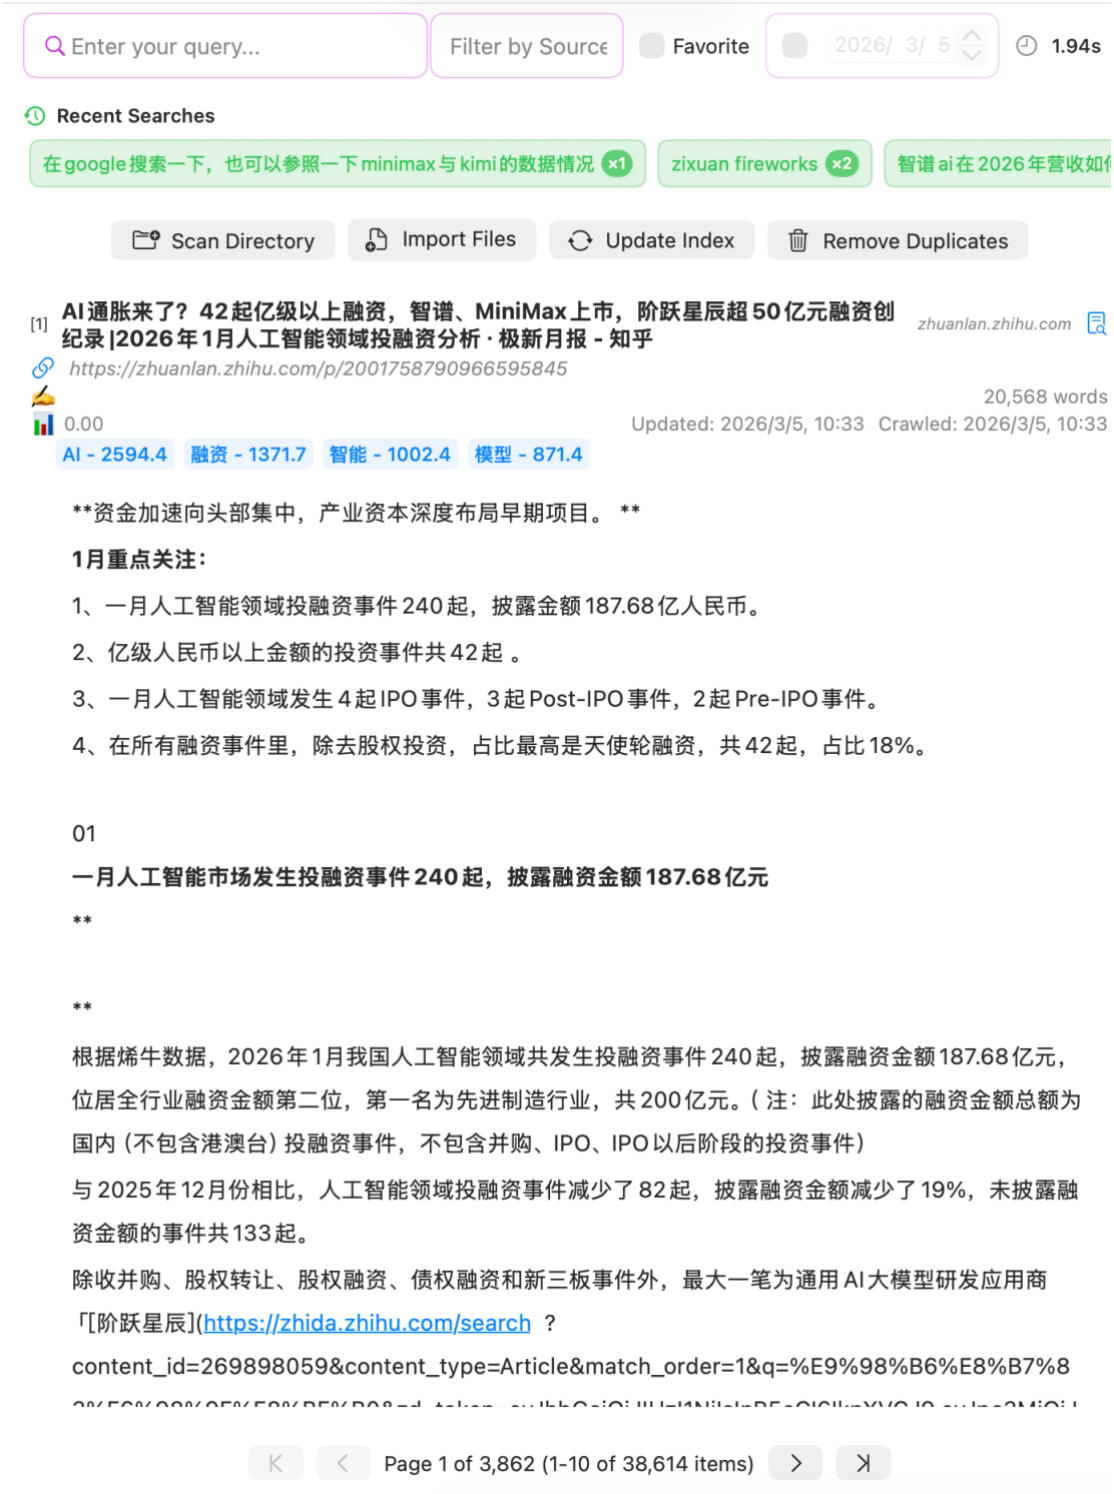

用户填入搜索词后，点击 Enter 开始搜索。界面会展示与基类似的用户输入、关键词、关键词联想提示、搜索用时，并且分页展示搜索结果。如果搜索出的知识过长，会被分块，并且只展示最相关的块内容。

下图展示的是完整的知识内容。

1.5浏览器界面

用户在对话的时候，部分工具会使用浏览器联网搜索内容，并且将搜索出来的内容保存到知识库，方便下次直接使用。工具在调用浏览器阅读的过程中，用户不要去操作浏览器界面。

用户也可以直接在地址输入框，直接填入目标地址访问，点击按钮“Extract”，这个内容会保存到知识库里面。

如果需要搜索小红书、X、Reddit，需要用户先登陆对应的账号，这样软件就可以在这些平台进行搜索操作。